

基于 MobileNetV3 与关键点融合的 摔倒检测系统设计

黄瀚文

(上海杉达学院 信息科学与技术学院, 上海 200135)

摘要:针对独居老人摔倒后难以及时发现问题, 本文设计并实现了一个基于深度学习的摔倒检测系统。系统采用双分支中期融合架构: 图像分支使用 MobileNetV3-Large 提取 960 维视觉特征, 关键点分支通过三层全连接网络将人体骨骼坐标编码为 64 维姿态表征, 二者拼接后送入分类器进行正常/摔倒二分类判断, 模型参数量约 332 万。在约 7800 张图像的数据集上完成训练与评估, 实验结果显示验证准确率为 48.13%, 摔倒类召回率为 57%。通过对实验结果的深入分析, 明确了关键点分支未完全激活、摔倒样本不足及单帧静态判定的局限性, 并提出了引入姿态估计、时序建模等改进方向。

关键词: 摔倒检测; 深度学习; MobileNetV3; 人体关键点; 计算机视觉

Design of a Fall Detection System Based on MobileNetV3 and Keypoint Fusion

Huang Hanwen

(School of Information Science and Technology, Sanda University, Shanghai 200135, China)

Abstract: To address the problem of detecting falls in elderly individuals living alone, this paper designs and implements a deep learning-based fall detection system. The system adopts a dual-branch intermediate fusion architecture: the image branch uses MobileNetV3-Large to extract 960-dimensional visual features, while the keypoint branch encodes human skeleton coordinates into a 64-dimensional pose representation through a three-layer fully connected network. The two are concatenated and fed into a classifier for binary classification of normal and fall states, with a total of approximately 3.32 million parameters. Training and evaluation were conducted on a dataset of about 7,800 images, yielding a validation accuracy of 48.13% and a fall class recall of 57%. Through in-depth analysis of the experimental results, the study identifies the incomplete activation of the keypoint branch, insufficient fall samples, and the inherent limitations of single-frame static classification as the primary causes of performance constraints. Improvement directions including the integration of pose estimation and temporal modeling are proposed.

Keywords: fall detection; deep learning; MobileNetV3; human keypoints; computer vision


第一章 绪论

1.1 研究背景与意义

随着人口老龄化加剧，独居老人数量持续增长，摔倒已成为老年人意外伤害和死亡的主要原因之一。摔倒后若未能在短时间内被发现和救助，存活率将大幅下降。传统的可穿戴式检测设备存在需要主动佩戴、电量有限、老人依从性差等问题。近年来，基于计算机视觉的摔倒检测技术因其非接触、部署灵活、可覆盖大范围区域等优势，成为该领域的研究热点。通过摄像头结合深度学习算法对画面进行分析，能够在摔倒事件发生时自动识别并发出预警，适用于居家养老、医院病房、养老机构等多种场景，具有重要的社会价值和广阔的应用前景。

1.2 国内外研究现状

视觉摔倒检测方法经过近二十年的发展，形成了两条主流技术路线：基于姿态估计的几何规则方法和基于深度学习的端到端分类方法。



几何规则方法先利用姿态估计算法（如 OpenPose、AlphaPose、MediaPipe 等）提取人体骨骼关键点坐标，再通过计算身体倾斜角度、躯干宽高比、头部运动速度等几何特征，结合阈值判断摔倒。Rougier 等人^[4]利用头部运动速度和加速度进行检测；Chua 等人^[5]则以肩膀与髋部连线的倾斜角为核心判据，并引入时序信息平滑判定。这类方法规则直观、可解释性强、计算开销小、适合实时部署，但高度依赖姿态估计精度，在遮挡、光线不足等场景下易出错。

深度学习方法直接从图像或视频中学习判别特征，将摔倒检测建模为二分类问题。早期

使用手工特征, 随后 AlexNet^[11]、VGG、ResNet^[10]等 CNN 网络被广泛应用。为进一步利用时序信息, 研究者将 CNN 与 LSTM 或 C3D 结合进行时空建模, 如 Sowmya 等人^[6]提出 CNN-LSTM 架构, Wang 等人^[7]将关键点热图与 RGB 图像拼接输入双流网络。深度学习方法能自动学习层次化特征, 在数据充分时效果优于规则方法, 但可解释性差、对标注数据依赖高、跨场景泛化能力不足。

多模态融合是近年来的重要趋势, 将图像纹理特征与骨骼姿态信息结合, 兼顾深度学习与姿态拓扑的优势。早期融合将关键点热图与图像拼接输入统一网络, 中期融合则分别编码后在特征层面拼接。然而, 这类方法的性能高度依赖关键点标注质量或姿态估计器精度, 如何在有限标注条件下有效发挥多模态融合潜力, 仍是待解决的问题。

1.3 本文主要工作

本文围绕摔倒检测任务, 设计并实现了一个图像与关键点双分支融合的分类系统。系统以 MobileNetV3-Large 为图像主干, 以多层感知机为关键点编码器, 将两种模态特征在中间层融合后送入分类器进行二分类判断, 模型参数量约 332 万。主要工作包括以下三个方面:

(1) 模型架构设计。图像分支使用预训练的 MobileNetV3-Large 提取 960 维视觉特征, 关键点分支通过三层全连接网络将人体 17 个骨骼关键点坐标编码为 64 维紧凑表征, 二者拼接为 1024 维联合向量后经分类器输出二分类结果, 兼顾了特征表达与轻量化部署的可行性。

(2) 数据处理与训练流水线。实现了 VOC 格式 XML 标注解析及图像归一化、标准化与数据增强的预处理流程。针对正常与摔倒样本约 7.5:1 的不平衡问题, 采用类别加权交叉熵损失函数, 并引入 ReduceLROnPlateau 学习率衰减和早停机制保存最佳模型。

(3) 实验评估与分析。在约 7800 张图像上完成训练与评估, 验证准确率为 48.13%, 摔倒类召回率为 57%。通过分析训练曲线、混淆矩阵和分类报告, 明确了关键点分支未激活、摔倒样本不足及单帧静态判定的局限性, 并提出了引入姿态估计、时序建模等改进方向。


第二章 相关技术与原理

2.1 MobileNetV3 特征提取网络

MobileNetV3 是 Google 于 2019 年提出的轻量级卷积神经网络^[1]，专为移动端和嵌入式设备的计算资源约束而设计。该网络在 MobileNetV2 的倒置残差结构基础上^[3]，引入了 SE (Squeeze-and-Excitation) 注意力模块与 NAS (Neural Architecture Search) 自动搜索的网络结构，并使用 h-swish 激活函数替代传统 ReLU，在保持较低参数量的同时显著提升了特征表达能力。

MobileNetV3 的核心构件是深度可分离卷积，它将标准卷积分解为逐通道的空间卷积和逐点的 1×1 卷积两个步骤，大幅减少了计算量和参数量，并通过 SE 模块对通道间的重要性进行自适应加权，增强了网络对关键特征的敏感度。MobileNetV3 提供 Small 和 Large 两个版本，本文选用 Large 版本作为图像特征提取主干。该版本在 ImageNet-1K 数据集上预训练^[15]，具有较强的通用视觉表征能力。在系统实现中，加载预训练权重后移除原网络末端的分类头，仅保留全局平均池化后的 960 维特征向量作为图像的全局表征，与关键点分支的编码输出拼接后送入融合分类器。

MobileNetV3 简化架构图



2.2 人体关键点编码

人体骨骼关键点能够提供人体姿态的空间拓扑信息，对于区分站立、弯腰、躺卧等姿态具有重要的判别价值。本文参考 COCO 17 关键点格式设计编码分支，覆盖头部、上肢、下肢等主要关节。预处理时，关键点坐标按图像尺寸线性缩放至 224×224 标准空间，17 个关键点展平为 34 维向量后输入编码器。


编码器采用三层全连接结构 ($34 \rightarrow 256 \rightarrow 128 \rightarrow 64$)，每层后接 BatchNorm、ReLU 和 Dropout(0.2)，逐层压缩形成紧凑的姿态表征，最终输出 64 维向量，为后续图像特征融合提供姿态先验。需说明的是，由于数据集仅提供边界框标注，缺乏骨骼关键点标签，编码器输

入暂时为零向量，该分支将在引入姿态估计模块后激活。

2.3 双分支特征融合策略

多模态融合策略是决定双分支模型性能的关键设计，可分为早期融合、中期融合和晚期融合三类。早期融合在输入层拼接各模态原始数据后送入统一网络；中期融合先用独立编码器提取特征后在中间层融合；晚期融合则在各模态完成推理后在决策层融合结果。

本文采用中期融合策略。图像分支经 MobileNetV3-Large 提取 960 维特征，关键点分支经三层全连接编码器输出 64 维特征，二者拼接为 1024 维联合表征后送入分类器。分类器结构为 $1024 \rightarrow 256 \rightarrow 128 \rightarrow 2$ ，每层后接 BatchNorm、ReLU 和 Dropout。前两层 Dropout 设为 0.3，略高于编码器的 0.2，以应对融合后更高的特征维度和参数量。最后一层输出 2 维向量，经 Softmax 归一化得到正常与摔倒的类别概率。



相较于单模态方案，双分支中期融合能同时利用图像的全局纹理信息和关键点空间结构信息，分类器可学习二者的互补关系，理论上比任意单一模态具有更强的判别能力。


第三章 系统设计与实现

3.1 系统整体架构

本系统的设计目标是构建一个端到端的摔倒检测模型，输入一张 RGB 图像，输出该图像中是否存在摔倒行为的二分类判断。系统整体架构分为数据处理、模型推理和训练调度三个主要模块，其工作流程如下：

首先，原始图像和对应的 XML 标注文件分别进入数据预处理模块。图像经尺寸归一化、标准化和数据增强后形成 $224 \times 224 \times 3$ 的张量；XML 标注经解析模块提取标签信息（正常/摔倒）和边界框坐标。处理后的图像张量与标签构成训练样本对，输入双分支模型进行前向传播。模型输出二分类预测结果，与真实标签计算加权交叉熵损失，通过反向传播更新模型参数。训练过程中，验证集按固定周期评估模型性能，根据验证准确率保存最佳模型，并在满足早停条件时终止训练。

推理阶段，加载保存的最佳模型，输入单张图像即可输出类别预测及其置信度，支持单张和批量两种预测模式。



3.2 数据集与预处理

3.2.1 数据集概述

本系统使用的数据集为公开的摔倒检测数据集，共包含约 7800 张 RGB 图像，按预设比例划分为训练集（约 6230 张）和验证集（约 1552 张）。数据集中图像涵盖了室内多种场景，包括不同光照条件、不同拍摄角度以及多人共存的复杂情况。每张图像对应一个同名

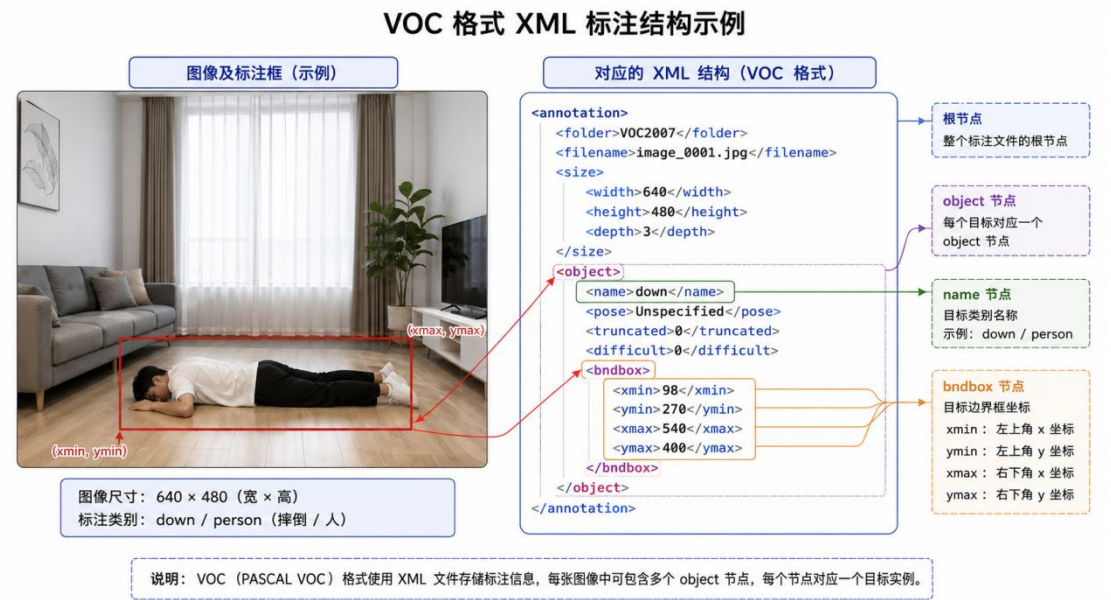
的 XML 标注文件，采用 VOC（Visual Object Classes）格式存储标注信息。

3.2.2 XML 标注解析

XML 标注文件的根节点为<annotation>，其中包含图像的尺寸信息（<size>中的宽度、高度和通道数）以及若干<object>子元素。每个<object>表示图像中的一个物体实例，其<name>字段标注该实例的状态类别——down 表示摔倒状态，person 表示正常状态。每个实例还包含一个<bndbox>边界框，以<xmin>、<ymin>、<xmax>、<ymax>四个坐标值标注人体的外接矩形位置。

在解析标签时，系统遍历 XML 文件中所有的<object>元素，检查其<name>字段值。若存在任意一个<name>为 down 的实例，则该图像的标签判定为摔倒（label=1）；否则判定为正常（label=0）。这一设计的依据在于：对于摔倒检测任务而言，图像中只要存在一个摔倒的人体，该场景即应触发预警，因此采用"宽松判定"策略——出现摔倒实例则整图标记为摔倒。

需要指出的是，当前数据集的 XML 标注以边界框为主，并未包含人体骨骼关键点信息。因此，系统在设计层面保留了关键点编码分支，但在本实验阶段该分支的输入暂时为零向量。



并除以标准差[0.229, 0.224, 0.225]。这一标准化操作使输入分布与 MobileNetV3 预训练时保持一致，有利于迁移学习的有效性。

为提升模型的泛化能力和对复杂场景的鲁棒性，训练集额外应用了三种数据增强策略：随机水平翻转（概率 0.5），模拟镜像场景；随机旋转（幅度 $\pm 10^\circ$ ），模拟摄像头安装角度偏差；色彩抖动（亮度、对比度各 ± 0.2 ），模拟不同光照环境。验证集仅进行尺寸归一化和标准化处理，以客观评估模型性能。

3.3 模型结构设计

本文设计的摔倒检测模型采用双分支中期融合架构，由图像分支、关键点分支和融合分类器三部分组成，模型整体参数量约 332 万。其结构配置如表 3-1 所示。

组件	结构	输出维度
图像分支	MobileNetV3-Large（预训练，移除分类头）	960
关键点编码器	FC(34→256)→BN→ReLU→Dropout(0.2)→FC(256→128)→BN→ReLU→Dropout(0.3)→FC(128→2)	64
特征融合	通道维度拼接	1024
分类器	FC(1024→256)→BN→ReLU→Dropout(0.3)→FC(256→128)→BN→ReLU→Dropout(0.3)→FC(128→2)	2


表 3-1 模型结构配置

图像分支以 MobileNetV3-Large 为骨干网络。该网络在 ImageNet-1K 大规模数据集上完成预训练，具备较强的通用视觉特征提取能力。本系统加载预训练权重后，将网络末端的分类头替换为恒等映射（nn.Identity()），仅保留全局平均池化后的 960 维特征向量。这一向量编码了图像的全局纹理、形状和场景语义信息，是判断人体状态的重要依据。

关键点编码器由三层全连接网络级联构成，输入为 17 个人体关键点的(x, y)坐标展平后得到的 34 维向量。第一层将输入映射至 256 维，第二层降至 128 维，第三层压缩至 64 维，形成紧凑的姿态表征。每层全连接后依次接有批量归一化（BatchNorm）以稳定训练、ReLU 激活函数以引入非线性、Dropout（概率 0.2）以抑制过拟合。64 维输出向量从坐标数据中抽象出人体的空间构型信息，捕捉站立、弯腰、躺卧等姿态的拓扑特征。

特征融合采用通道维度拼接（Concatenation）方式，将图像分支的 960 维特征与关键点分支的 64 维特征在维度上进行拼接，得到 1024 维的联合表征。拼接操作保留了各分支

特征的完整性，使后续分类器能够按需学习两个模态之间的互补关系。



分类器由三层全连接网络构成，结构为 $1024 \rightarrow 256 \rightarrow 128 \rightarrow 2$ 。前两层负责逐步压缩和精炼联合特征，每层后接 BatchNorm、ReLU 和 Dropout（概率 0.3）。融合后的联合特征维度较高，因此分类器中的 Dropout 概率设置得比关键点编码器略高，以施加更强的正则化。最后一层全连接输出 2 维向量，经 Softmax 函数归一化后得到正常和摔倒两个类别的预测概率。

3.4 训练策略

3.4.1 损失函数

本任务为二分类问题，采用交叉熵损失函数（CrossEntropyLoss）作为优化目标。然而，数据集中正常样本数量远多于摔倒样本，存在显著的类别不平衡。若使用标准交叉熵损失，模型会被大量正常样本主导，倾向于将所有输入预测为正常类，导致摔倒类的召回率极低。为缓解这一问题，本系统采用类别加权策略，为每个类别赋予与样本数成反比的权重。权重的计算公式为：

$$\text{Weight}_i = N / (2 * n_i)$$

其中 N 为训练集总样本数， n_i 为第 i 类的样本数。该公式使得样本数较少的类别获得更高的损失权重，模型在对该类样本产生误判时将受到更大的惩罚，从而引导模型更加关注少数类的正确分类。

3.4.2 优化器与学习率调度

优化器选用 AdamW。AdamW^[12]在 Adam 的基础上将权重衰减（Weight Decay）与自适应学习率解耦，能够在保持 Adam 快速收敛优势的同时实现更有效的正则化。本系统中学习率初始值设为 1×10^{-4} ，权重衰减系数设为 1×10^{-4} 。

学习率调度采用 ReduceLROnPlateau 策略。该策略以验证集损失为监控指标，当连续 5 个训练轮次内验证损失未出现下降时，将学习率衰减为当前值的 50%。这种自适应的学习率调整机制能够在训练进入平台期后自动降低步长，帮助模型在参数空间中更精细地搜索最优解，避免因学习率过大而在最优点附近震荡。

3.4.3 早停与模型保存

为防止过拟合并节省训练时间，系统引入了早停机制。训练过程中持续跟踪验证集准确率，若连续 10 个轮次未出现提升，则判定模型已收敛，自动终止训练。这一策略避免了在性能不再提升的情况下继续无效迭代。

模型选择采用最佳验证准确率准则。在每个训练轮次结束后，比较当前轮次的验证准确率与历史最佳值。若当前准确率优于历史最佳，则将模型的状态字典和验证准确率一并保存至指定路径；否则仅记录历史数据，不更新保存的模型文件。训练结束后，检查点文件中保存的即为整个训练过程中验证准确率最高的模型，可直接用于推理。

3.4.4 超参数配置

系统的主要超参数经多次调试后确定，汇总于表 3-2。批次大小受限于硬件内存容量，设为 16 以在训练速度和显存占用之间取得平衡。最大训练轮次设为 50，但在实际训练中通常因早停机制而提前终止。

参数	取值
输入图像尺寸	224*224
批次大小	16
初始学习率	1×10^{-4}
权重衰减	1×10^{-4}
最大训练轮次	50
早停耐心值	10

学习率衰减耐心值	5
学习率衰减因子	0.5
Dropout（编码器）	0.2
Dropout（分类器）	0.3

表 3-2 超参数配置表

3.4.5 本章小结

本章从系统架构、数据处理、模型结构和训练策略四个方面详细阐述了摔倒检测系统的设计与实现。系统采用双分支中期融合架构，以 **MobileNetV3-Large** 为图像特征提取骨干，以三层全连接网络为关键点编码器，二者在中间层拼接后送入分类器进行二分类判断。数据预处理阶段实现了 VOC 格式 XML 的标签解析和图像标准化、增强流水线。训练阶段引入类别加权损失、自适应学习率衰减和早停机制，以应对数据不平衡和过拟合问题。

第四章 实验与结果分析

4.1 实验环境

本实验的软硬件环境配置如表 4-1 所示。

配置项	说明
操作系统	macOS
处理器	Apple M5Pro
深度学习框架	PyTorch 2.x ^[14]
编程语言	Python 3.8
CUDA/MPS	Apple MPS 加速
关键依赖库	torchvision, NumPy, PIL, Matplotlib, Seaborn, scikit-learn
数据集	https://www.modelscope.cn/datasets/DatatangBeijing/10142Videos-FallBehaviorData

表 4-1 实验软硬件配置表

4.2 数据集划分与类别分布

实验数据集共包含约 7800 张 RGB 图像，按预设比例划分为训练集和验证集。经 XML 标注解析后，两个集合的类别分布如表 4-2 所示。

类别	训练集	验证集	合计
正常	5600	1261	6860
摔倒	630	291	920
合计	6230	1552	7782

表 4-2 数据集类别分布

从表 4-2 可以看出，数据集中存在明显的类别不平衡现象。正常样本数量约为摔倒样本的 7.5 倍，这在真实场景中具有一定合理性，实际监控画面中大部分时间人体处于正常状态，摔倒事件相对稀疏。然而，这种不平衡会给模型训练带来挑战，因为标准损失函数容易被多数类主导，导致模型倾向于将所有样本预测为正常类，从而产生大量的假阴性（漏报）。针对这一问题，本实验在训练过程中引入了类别加权损失策略，为摔倒类赋予更高的损失权重，以鼓励模型关注少数类样本的正确分类。

4.3 训练过程分析

模型共训练了多个轮次，训练过程中记录每个轮次的训练损失、训练准确率、验证损失和验证准确率四项指标，其变化曲线如图 4-1 所示




图 4-1 训练曲线图

从损失曲线可以看出，训练损失从初始值约 0.68 持续下降至约 0.15 附近，验证损失从约 0.70 下降至约 1.45 后逐步攀升。两条损失曲线在初始轮次较为接近，随后出现明显分化——训练损失继续下降而验证损失反向上升。这一“剪刀差”现象是过拟合的典型信号，表明模型在训练集上不断拟合细节特征的同时，在验证集上的泛化性能并未同步提升。

从准确率曲线可以看出，训练准确率从约 38% 逐步上升至约 64%，验证准确率从约 42% 上升至约 48% 后趋于平稳。两条准确率曲线之间存在约 10 至 16 个百分点的差距，且训练准确率始终高于验证准确率，与损失曲线的分化趋势相互印证。综合来看，模型在第 5 至第 8 轮附近验证准确率达到相对最优（约 48%），此后训练准确率继续提升而验证准确率基本不变甚至略有下降，表明此时模型已进入过拟合阶段。得益于早停机制的引入，训练在验证准确率不再提升后自动终止，保留了泛化能力最好的模型检查点。

需要指出的是，模型整体准确率仅略低于二分类随机基准线（50%），说明在仅使用图像特征且缺乏关键点信息的情况下，模型未能充分学习到区分正常与摔倒的有效判别模式。这一问题将在 4.4 节结合分类报告和混淆矩阵进行更详细的分析。

4.4 分类结果评估

训练结束后，使用保存的最佳模型对验证集全部 1552 张图像进行推理评估，得到的混淆矩阵如图 4-2 所示。




表 4-2 混淆矩阵

从混淆矩阵和分类报告可以得出以下分析结果：

(1) 正常类的表现。正常类精确率为 0.82，即当模型预测为"正常"时，有 82% 的概率确实是正常样本。然而，正常类的召回率仅为 0.46，即验证集中 1261 张正常图像中，仅 46%（581 张）被正确识别，其余 54%（680 张）被误判为摔倒。这意味着模型存在严重的误报问题——大量正常姿态被错误地判定为摔倒。误报率过高在实际应用中会频繁触发虚警，降低用户对系统可靠性的信任度。

(2) 摔倒类的表现。摔倒类的召回率为 0.57，即验证集中 291 张摔倒图像中，有 57%（166 张）被正确识别。这一数值仅略高于随机猜测水平（50%），表明模型对真实摔倒样本的检出能力十分有限。摔倒类的精确率仅为 0.20，即当模型判定为"摔倒"时，仅有 20% 的可能性是正确的，另外 80% 是误报。精确率低与正常类的大量误报密切相关——模型过度倾向于输出"摔倒"预测，导致假阳性数量剧增，淹没了真实的正类检测结果。

(3) 综合表现。模型整体准确率为 48.13%，宏平均 F1-score 为 0.44。准确率低于 50% 说明在该验证集上，模型的分类能力强于随机猜测。从实际应用角度看，对于摔倒检测这一安全敏感任务，召回率（尤其摔倒类的召回率）比精确率和整体准确率更为重要——漏掉一次真实摔倒事件的代价远大于触发一次误报。当前摔倒类召回率 57%，意味着有 43% 的摔倒事件会被遗漏，这一性能尚不满足实用部署的要求。

4.5 结果讨论与局限性分析

模型性能偏低的主要原因可归纳为以下几个方面：

(1) 关键点分支未激活。由于数据集仅提供边界框标注，缺乏骨骼关键点坐标，关键点编码器输入始终为零向量，模型实际退化为纯图像分类器。摔倒与弯腰、蹲下等正常姿态在图像空间上高度相似，仅靠全局纹理特征难以有效区分，而骨骼空间拓扑关系的缺失直接限制了模型的判别能力。

(2) 数据量不足与类别不平衡。数据集总体约 7800 张，但摔倒类仅约 920 张，训练集中更只有约 630 张，难以覆盖多样化的摔倒姿态和复杂环境。类别加权策略虽缓解了不平衡，但无法弥补少数类绝对数量不足导致的特征学习不充分。

(3) 场景多样性有限。数据集可能来自有限场景的连续帧采样，训练集与验证集在场景、人物和背景上高度重叠，验证集难以充分测试模型对全新场景的泛化能力。

(4) 静态单帧判定的固有局限。摔倒本质上是动态过程，本系统仅对单帧图像分类，无法利用帧间的运动特征（如关节速度、重心加速度等）。躺着休息与摔倒后倒地等易混淆姿态在缺乏运动上下文时几乎无法可靠区分，从根本上限制了静态方法的性能上限。

4.6 改进方向

针对上述局限性，可以从以下几个方面对系统进行改进：

(1) 激活关键点分支。引入预训练的人体姿态估计模型（如 MediaPipe^[9]、OpenPose^[8]、MMPose 等）自动提取图像中的人体关键点坐标，为模型的关键点编码器提供真实输入。这一改进无需修改数据集标注，可以充分利用现有数据激活双分支融合架构的完整潜力。

(2) 扩充与丰富数据集。收集更多样化的摔倒检测公开数据集（如 UR Fall Detection、Le2i Fall Detection、Multiple Cameras Fall Dataset 等），增加摔倒样本的数量和姿态多样性。同时可通过数据合成技术（如对现有摔倒图像进行背景替换、人物仿射变换等）扩充少数类样本。

(3) 引入时序信息。将单帧分类扩展至视频片段分析，使用 LSTM、GRU 或 3D 卷积网络捕捉连续帧之间的运动模式。时序模型能够利用人体的运动轨迹和速度变化来区分摔倒与其他相似姿态，有望显著提升检测的准确率和召回率。

(4) 优化数据划分策略。采用交叉验证或按场景、人物进行严格划分，确保验证集与训练集在场景和人物层面相互独立，以更客观地评估模型的实际泛化能力。

第五章 总结与展望

5.1 工作总结

本文围绕摔倒检测任务，设计并实现了一个图像与关键点双分支融合的分类系统，完成了从数据处理、模型训练到实验评估的完整流程。主要工作总结如下：

(1) 模型架构方面。构建了以 MobileNetV3-Large 为图像主干、以三层全连接网络为关键点编码器的双分支中期融合模型，参数量约 332 万，兼顾了特征表达能力与轻量化部署的可行性。

(2) 数据处理方面。实现了 VOC 格式 XML 标注解析及图像标准化与增强流水线，针对正常与摔倒样本约 7.5:1 的不平衡问题，采用类别加权损失函数，并引入学习率自适应衰减和早停机制。

(3) 实验分析方面。在约 7800 张图像上完成评估，验证准确率为 48.13%，摔倒类召回率为 57%。分析表明，关键点分支未激活、摔倒样本不足及单帧静态判定的局限性是性能受限的主要原因，并据此提出了改进方向。

5.2 未来展望

针对当前系统的局限性，后续可从以下方面改进：

(1) 激活关键点分支。引入 MediaPipe、OpenPose 等预训练姿态估计模型自动提取骨骼关键点坐标，在不增加标注成本的前提下激活双分支融合架构的完整能力。

(2) 引入时序建模。将单帧分类扩展至视频片段分析，采用 LSTM、GRU 或时序 Transformer 捕捉连续帧间的运动轨迹和姿态变化，利用摔倒过程的动态特征突破静态方法的性能瓶颈。

(3) 扩充数据规模。整合多个公开摔倒检测数据集，增加样本的姿态多样性和场景覆盖度，并结合背景替换、仿射变换等合成技术扩充少数类样本。

(4) 模型轻量化与边缘部署。探索模型量化、剪枝和知识蒸馏等压缩技术，在保持检测性能的同时降低计算开销，将系统部署至树莓派等边缘设备，实现低功耗、低延迟的实时检测。

致谢 感谢毕卓教授对本工作的大力支持，在此表示感谢！

附录 A.1 模型结构定义

以下代码定义了双分支摔倒检测模型。图像分支使用预训练的 MobileNetV3-Large 提取 960 维视觉特征，关键点分支通过三层全连接网络将人体 17 个骨骼关键点坐标编码为 64 维姿态表征，二者拼接后送入三层全连接分类器进行二分类判断

```
class FallDetectionModel(nn.Module):
    def __init__(self, num_keypoints=17, num_classes=2):
        super().__init__()
        # 图像分支：预训练 MobileNetV3-Large，移除分类头
        self.backbone = models.mobilenet_v3_large(
            weights=models.MobileNet_V3_Large_Weights.IMAGENET1K_V1
        )
        backbone_dim = 960
        self.backbone.classifier = nn.Identity()
        # 关键点编码器：三层全连接 (34→256→128→64)
        self.kp_encoder = nn.Sequential(
            nn.Linear(num_keypoints * 2, 256),
            nn.BatchNorm1d(256),
            nn.ReLU(inplace=True),
            nn.Dropout(0.2),
            nn.Linear(256, 128),
            nn.BatchNorm1d(128),
            nn.ReLU(inplace=True),
            nn.Dropout(0.2),
            nn.Linear(128, 64)
        )
        # 分类器：三层全连接 (1024→256→128→2)
        self.classifier = nn.Sequential(
            nn.Linear(backbone_dim + 64, 256),
            nn.BatchNorm1d(256),
            nn.ReLU(inplace=True),
            nn.Dropout(0.3),
            nn.Linear(256, 128),
            nn.BatchNorm1d(128),
            nn.ReLU(inplace=True),
            nn.Dropout(0.3),
            nn.Linear(128, num_classes)
        )

    def forward(self, image, keypoints, visibility=None):
```

```

img_feat = self.backbone(image)          # 图像特征: 960 维
kp_feat = self.kp_encoder(keypoints)     # 关键点特征: 64 维
combined = torch.cat([img_feat, kp_feat], dim=1) # 拼接: 1024 维
return self.classifier(combined)

```

A.2 数据集类

以下代码实现了 VOC 格式 XML 标注文件的解析与图像预处理流水线。解析模块通过遍历 XML 中的<object>元素提取类别标签（down 为摔倒，person 为正常），训练阶段应用随机翻转、旋转和色彩抖动进行数据增强。

```
class FallDataset(Dataset):
```

```
    def parse_xml(self, xml_path):
```

```
        try:
```

```
            tree = ET.parse(xml_path)
```

```
            root = tree.getroot()
```

```
            label = 0
```

```
            keypoints = np.zeros((17, 3), dtype=np.float32)
```

```
            # 遍历所有<object>, 找<name>down</name>
```

```
            for obj in root.findall('object'):
```

```
                name_elem = obj.find('name')
```

```
                if name_elem is not None and name_elem.text:
```

```
                    name = name_elem.text.strip().lower()
```

```
                    if name in ['down', 'fall', 'fallen']:
```

```
                        label = 1
```

```
                        break
```

```
            return {'label': label, 'keypoints': keypoints}
```

```
        except Exception as e:
```

```
            return {'label': 0, 'keypoints': np.zeros((17, 3), dtype=np.float32)}
```

```
    def __getitem__(self, idx):
```

```
        img_path = self.image_files[idx]
```

```
        image = Image.open(img_path).convert('RGB')
```

```
        # 加载对应 XML 标注
```

```
        xml_path = self.xmls_dir / f'{img_path.stem}.xml'
```

```
        if xml_path.exists():
```

```
            ann = self.parse_xml(xml_path)
```

```
        else:
```

```
            ann = {'label': 0, 'keypoints': np.zeros((17, 3), dtype=np.float32)}
```

```
        # 图像变换 (含归一化与标准化)
```

```
        if self.transform:
```

```
            image = self.transform(image)
```

```
        return {
```

```
            'image': image,
```

```
            'keypoints': torch.tensor(ann['keypoints'][:, :2].flatten(), dtype=torch.float32),
```

```
            'visibility': torch.tensor(ann['keypoints'][:, 2], dtype=torch.float32),
```

```
            'label': torch.tensor(ann['label'], dtype=torch.long)
```

A.3 训练器

以下代码实现了模型训练的核心逻辑，包括按类别样本数反比加权的交叉熵损失、AdamW 优化器、ReduceLROnPlateau 学习率自适应衰减以及基于验证准确率的早停机制。

class Trainer:

```
def train(self, train_loader, val_loader, class_weights=None):
    if class_weights:
        self.criterion = nn.CrossEntropyLoss(
            weight=torch.FloatTensor(class_weights).to(self.config.DEVICE)
        )
    best_acc = 0
    patience = 0
    for epoch in range(self.config.EPOCHS):
        train_loss, train_acc = self.train_epoch(train_loader)
        val_loss, val_acc, _, _ = self.validate(val_loader)
        # 学习率自适应衰减
        self.scheduler.step(val_loss)
        # 保存最佳模型
        if val_acc > best_acc:
            best_acc = val_acc
            torch.save({
                'model_state_dict': self.model.state_dict(),
                'val_acc': val_acc
            }, self.config.MODEL_SAVE_PATH)
            patience = 0
        else:
            patience += 1
            # 早停机制
            if patience >= 10:
                print(f'早停! 最佳准确率: {best_acc:.2f}%')
                break
    return self.history
```

A.4 数据增强

训练集应用三种数据增强策略，验证集仅进行尺寸归一化和标准化。

def get_transforms(img_size=224, is_train=True):

```
    if is_train:
        return transforms.Compose([
            transforms.Resize((img_size, img_size)),
            transforms.RandomHorizontalFlip(p=0.5),          # 随机水平翻转
            transforms.RandomRotation(10),                   # 随机旋转±10°
            transforms.ColorJitter(brightness=0.2, contrast=0.2), # 色彩抖动
            transforms.ToTensor(),
            transforms.Normalize([0.485, 0.456, 0.406], [0.229, 0.224, 0.225])
        ])
    else:
        return transforms.Compose([
            transforms.Resize((img_size, img_size)),
            transforms.ToTensor(),
            transforms.Normalize([0.485, 0.456, 0.406], [0.229, 0.224, 0.225])
        ])
```

```

return transforms.Compose([
    transforms.Resize((img_size, img_size)),
    transforms.ToTensor(),
    transforms.Normalize([0.485, 0.456, 0.406], [0.229, 0.224, 0.225])
])

```

参考文献:

- [1] Howard A, Sandler M, Chu G, et al. Searching for MobileNetV3[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). Seoul: IEEE, 2019: 1314-1324.
- [2] Tan M, Le Q V. EfficientNet: Rethinking model scaling for convolutional neural networks[C]// Proceedings of the International Conference on Machine Learning (ICML). Long Beach: PMLR, 2019: 6105-6114.
- [3] Sandler M, Howard A, Zhu M, et al. MobileNetV2: Inverted residuals and linear bottlenecks[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Salt Lake City: IEEE, 2018: 4510-4520.
- [4] Rougier C, Meunier J, St-Arnaud A, et al. Fall detection from human shape and motion history using video surveillance[C]// Proceedings of the 21st International Conference on Advanced Information Networking and Applications Workshops (AINAW). Niagara Falls: IEEE, 2007: 875-880.
- [5] Chua J L, Chang Y C, Lim W K. A simple vision-based fall detection technique for indoor video surveillance[J]. Signal, Image and Video Processing, 2015, 9(3): 623-633.
- [6] Sowmya V, Nair M S, Colaco S, et al. Fall detection in elderly care using convolutional neural networks and long short-term memory networks[J]. Journal of Ambient Intelligence and Humanized Computing, 2021, 12(1): 751-763.
- [7] Wang B, Guo L, Zhang H, et al. A vision-based fall detection network by using 2D skeleton and RGB images[J]. IEEE Sensors Journal, 2022, 22(6): 5768-5777.
- [8] Cao Z, Simon T, Wei S E, et al. Realtime multi-person 2D pose estimation using part affinity fields[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu: IEEE, 2017: 7291-7299.
- [9] Lugaresi C, Tang J, Nash H, et al. MediaPipe: A framework for building perception pipelines[J]. arXiv preprint arXiv:1906.08172, 2019.
- [10] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas: IEEE, 2016: 770-778.
- [11] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[C]// Advances in Neural Information Processing Systems (NIPS). Lake Tahoe: Curran Associates, 2012: 1097-1105.
- [12] Loshchilov I, Hutter F. Decoupled weight decay regularization[C]// Proceedings of the International Conference on Learning Representations (ICLR). New Orleans: OpenReview.net, 2019.
- [13] Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[C]// Proceedings of the IEEE International Conference on Computer Vision (ICCV). Venice: IEEE, 2017: 2980-2988.
- [14] Paszke A, Gross S, Massa F, et al. PyTorch: An imperative style, high-performance deep learning library[C]// Advances in Neural Information Processing Systems (NeurIPS). Vancouver: Curran Associates, 2019: 8024-8035.
- [15] Deng J, Dong W, Socher R, et al. ImageNet: A large-scale hierarchical image database[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Miami: IEEE, 2009: 248-255.